

基于 RBF 神经网络的光纤陀螺温度补偿

杨国梁, 徐烨烽, 徐海刚

(北京航空航天大学 仪器科学与光电工程学院, 北京 100083)

摘要:针对某型捷联惯导系统中光纤陀螺仪的输出信号随温度漂移严重的问题,使用径向基函数(RBF)神经网络建立温度补偿模型。神经网络的结构为输入层和输出层各有一个节点,中间隐层含有4个节点,隐层节点的聚类中心均匀分布在温度的变化范围之内。实验结果表明,该方法可有效地将光纤陀螺仪中的温漂误差减小1个数量级以上,补偿效果明显。

关键词:光纤陀螺;径向基函数(RBF)神经网络;温度补偿

中图分类号: TN915; V241.5

文献标识码: A

Temperature Compensation for FOG Based on RBF Neural Networks

YANG Guoliang, XU Yefeng, XU Haigang

(School of Instrumentation Science & Optoelectronics Engineering, Beijing University of Aeronautics & Astronautics, Beijing 100083, China)

Abstract: In the view of serious temperature excursion of the fiber optic gyroscope(FOG) in a strapdown inertial navigation system, a temperature compensation model is established by using RBF neural network. The input layout and output layout of the neural network have one node separately, the middle layout has four nodes, and the aggregation center points of the nodes in the middle layout are scattered evenly among the changing area of the temperature. It is proved by the experiment that this method could reduce the gyro's temperature excursion at least 1 order of magnitude in comparison with the traditional method. The effect of compensation is distinct.

Key words: fiber optic gyroscope (FOG); RBF neural network; temperature compensation

温度是影响光纤陀螺(FOG)偏置漂移的主要因素之一。通常的方法是利用实验数据建立温度与陀螺漂移的关系,但用一般的线性模型和多项式的非线性模型都难以达到精确描述。神经网络可在 L_2 范数上拟合任意的非线性函数,故可用神经网络建立陀螺的温度模型进行补偿^[1]。

在神经网络中常用BP网络来实现辨识功能,但BP网络存在局部极小,收敛速度慢等缺点。径向基函数(RBF)网络是一种在逼近能力、分类能力和学习速度方面都优于BP网络的神经网络,它用局部逼近的总和来达到对训练数据的全局逼近,从而实现全局最优^[2]。此外,RBF网络是一种特殊的两层网络,其参数由于RBF中心的固定而得以线性化,因此隐层充当了无调节参数的固定的非线性转化环节。它将输入空间映射到一个新空间,唯一的调节参数是线性迭加权值,这些参数可采用线性最小方差(LS)得到,这就是RBF网络的优势所在。基于以上原因,本文选择RBF网络对光纤陀螺进行温漂辨识。

1 RBF网络结构和学习方法

1.1 RBF网络结构^[3]

采用具有 n 个输入和1个输出的RBF网络结

构如图1所示,其中, X_1, X_2, \dots, X_n 为 $1, 2, \dots, n$ 个输入; W_1, W_2, \dots, W_n 为 $1, 2, \dots, n$ 个输出偏置。此网络实现了 $f: R^n \rightarrow R$ 的映射:

$$f(x) = \omega_0 + \sum_{i=1}^m \omega_i \phi_i(x) \quad (1)$$

式中 $x \in R^n$ 为输入量; $\phi(\cdot)$ 为非线性转换函数; ω_0 和 $\omega_i (1 \leq i \leq m)$ 分别为输出层偏置和权值; m 为中心个数。




图1 RBF网络结构图

由图1可知,RBF网络输入到隐单元的权值固定为1,可看作由含有径向基神经元的隐层和含有线性神经元的输出层两层组成。隐层中每个神经元中心和局部感受域决定了RBF的位置和宽度;输出层神经元将隐层的RBF加权叠加,只要选择足够的隐层神经元、适当的中心、局部感受域和权值,RBF

网络可任意精度拟合任意函数。在 RBF 网络中假设 $\phi(\cdot)$ 是固定的, 本文采用基函数为高斯函数, 描述为

$$\phi_i(x) = \exp(-\|x - c_i\|^2 / 2\beta_i^2) \quad i=1, 2, \dots, m \quad (2)$$

式中 ϕ_i 为第 i 个隐层节点的输出; c_i 为第 i 高斯函数的中心, 它的维数与 x 相同; β_i 为第 i 个高斯函数的高度, 它决定了基函数的敏感区域; $\|x - c_i\|^2$ 为向量范数, 表示 x 与 c_i 间的距离。

1.2 RBF 网络学习方法

用 RBF 网络学习方法有多种^[4], 本文采用正交最小二乘法(OLS)。OLS 法通过“新息-贡献”准则进行正交优选中心, 具有简单易行、精度高和速度快等优点, 但不足之处是不适合做递推运算。温漂识别可离线进行, 不要求递推, 故可采用 OLS 法。

OLS 法首先须选定 RBF 网络的 $\phi(\cdot)$ 及局部感受域 δ 。设训练样本数为 N , 样本中的输入作为网络的初始中心, 并经转化函数(隐层)得到隐层输出的基矢量 P , 之后的线性迭加就相当于线性回归模型:

$$\hat{d} = P\Theta + E \quad (3)$$

式中 $\hat{d} = [\hat{d}(1) \hat{d}(2) \dots \hat{d}(N)]^T$ 为估计输出; $P = [p_1 p_2 \dots p_N]$; $p_i = [p_i(1) p_i(2) \dots p_i(N)]^T$ ($1 \leq i \leq N$) 为回归因子; $\Theta = [\Theta_1 \Theta_2 \dots \Theta_N]^T$ 为线性权值; $E = [\epsilon(1) \epsilon(2) \dots \epsilon(N)]^T$ 为误差。

LS 法是要寻找权值 Θ , 使 $P\Theta$ 能最佳估计期望输出 d 。OLS 法是将相关的回归因子经正交变化, 从而可分别算得各因子对输出能量的贡献。回归矩阵:

$$P = WA \quad (4)$$

式中 A 为 $N \times N$ 的上三角矩阵; W 为正交列为 ω_i 的 $N \times N$ 正交矩阵; $W^T W = H$, H 的对角元素 $h_i = \omega_i^T \omega_i$ ($1 \leq i \leq N$)。在实际计算时, 常采用经典的 Gram-Schmidt 递推法对矩阵 P 进行正交分解, 其计算步骤为

$$\omega_1 = p_1 \quad (5)$$

$$a_k = \omega_k^T p_k / \omega_k^T \omega_k \quad 1 \leq i \leq k \quad (6)$$

$$\omega_k = p_k - \sum_{i=1}^{k-1} a_{ki} \omega_i \quad k=2, 3, \dots, N \quad (7)$$

因此线性回归模型可重写为

$$\hat{d} = Wg + E \quad (8)$$

式中 $g = A\Theta$ 。要使线性回归模型的输出能够最佳估计期望输出 d , 采用 LS 法可解出:

$$g = H^{-1} W^T d \quad (9)$$

$$g_i = \omega_i^T d / \omega_i^T \omega_i \quad 1 \leq i \leq N \quad (10)$$

前面已把采集样本的输入作为初始中心, 此时网络回归因子有 N 个, 由于一般采集样本的数目 N

万方数据

很大, 而一个能够充分描述系统的网络模型仅需其中 $N_s (\ll N)$ 个较为重要的因子, 这些重要的因子可通过采用 OLS 法选择出来。由于 ω_i 和 ω_j ($i \neq j$) 是正交的, 因而输出能量可表示为

$$d^T d = \sum_{i=1}^N g_i^2 \omega_i^T \omega_i + E^T E \quad (11)$$

式中 $\sum_{i=1}^N g_i^2 \omega_i^T \omega_i$ 为期望输出能量的有用部分; $E^T E$ 为误差部分。系统描述的 N_s 个重要因子和相应的网络中心为:

$$[cont]_i = g_i^2 \omega_i^T \omega_i / d^T d \quad 1 \leq i \leq N \quad (12)$$

综上所述, 采用 OLS 递推法的 RBF 网络建立步骤如下:

(1) 设样本输入为网络的初始中心, 选定非线性性和局部感受阈值, 计算隐层输出(即回归因子) P , 然后进行下列计算:

$$\begin{cases} \omega_1^{(1)} = p_1 \\ g_1^{(1)} = (\omega_1^{(1)})^T d / (\omega_1^{(1)})^T \omega_1^{(1)} \quad 1 \leq i \leq N \\ [cont]_1^{(1)} = (g_1^{(1)})^2 (\omega_1^{(1)})^T \omega_1^{(1)} / d^T d \end{cases} \quad (13)$$

寻找

$$[cont]_i^{(1)} = \max\{[cont]_i^{(1)}\} \quad 1 \leq i \leq N \quad (14)$$

选择正交因子的首列 $\omega_1 = \omega_1^{(1)} = p_{i_1}$, 并选定样本中第 i_1 组作为网络的第 1 个中心。

(2) 在第 $K (\geq 2)$ 步计算:

$$\begin{cases} a_{jk}^{(i)} = \omega_j^T p_i / \omega_j^T \omega_j \\ \omega_k^{(i)} = p_i - \sum_{j=1}^{k-1} a_{jk}^{(i)} \omega_j \\ g_k^{(i)} = (\omega_k^{(i)})^T d / (\omega_k^{(i)})^T \omega_k^{(i)} \\ [cont]_k^{(i)} = (g_k^{(i)})^2 (\omega_k^{(i)})^T \omega_k^{(i)} / d^T d \end{cases} \quad (15)$$

式中 $1 \leq j \leq k, 1 \leq i \leq N, i \neq i_1, \dots, i \neq i_{k-1}$, 寻找 $[cont]_k^{(i_k)} = \max\{[cont]_k^{(i)}\}, 1 \leq i \leq N, i \neq i_1, \dots, i \neq$

i_{k-1} 。选择正交因子的 k 列 $\omega_k = p_i - \sum_{j=1}^{k-1} a_{jk}^{(i)} \omega_j$, 并选定样本中第 i_k 组作为网络的第 k 个中心。

(3) 检验以下关系是否满足(假设进行到第 M_s 步)。如果满足, 采用 LS 法确定出权值 Θ ; 若不满足, 则继续第(2)步:

$$1 - \sum_{j=1}^{M_s} [cont]_j < \rho \quad 0 < \rho < 1 \quad (16)$$

式中 ρ 为误差限度。

2 RBF 神经网络用于温漂补偿

采集陀螺仪静态的输出和惯组的工作温度, 直到惯组达到热平衡, 得到 3 个通道的陀螺仪输出 ω 和温度输出 T 。采用 RBF 神经网络对 3 个通道分别建立温度补偿模型, 每个网络以温度信号为输入, 以陀螺仪的温度漂移为目标输出。神经网络结构为

输入层和输出层各有 1 个节点。考虑温度变化是连续过程,因此设定聚类中心均匀分布在温度的变化范围内。通过反复比较,聚类中心数设为 4 较合适,即隐层选取 4 个节点。

陀螺原始数据采样频率为 100 Hz,温度采样频率为 1 Hz。实际处理中先对陀螺信号进行 1 s 平均,使其与温度信号采样频率一致;同时为了消除大范围输入对网络参数学习的不确定性影响,还要对温度信号和陀螺信号进行归一化处理,即可得到归一化后的温度信号 t_1 和陀螺信号 w_1 ,并将其作为教师样本对神经网络进行训练。

当网络实际输出与输出样本间的误差在允许范围内时,训练宣告结束后,网络的权系数和阈值最终确定并存储在网络内,从而确立了输入/输出的函数关系 f 。由测量到的 T 可计算出惯组各路陀螺仪的温漂 u ,然后用测量到的各路 ω 减去网络估计出的陀螺温漂就得到温度补偿后的信号 W ,即 $u = f(T)$, $W = \omega - u$ 。以 x 轴陀螺仪信号为例,输入信号和目标信号如图 2 所示。




图 2 归一化的输入信号和目标信号

初始化网络权值和阈值为均匀分布的较小数值,网络训练结束后,实际输出和目标信号输出的均方差小于 1×10^{-3} ,如图 3 所示,可满足要求。温度补偿前后的陀螺输出如图 4 所示。






图 3 输出结果和目标信号之间的误差




(a) 补偿前



(b) 补偿后

图 4 温度补偿结果

为了进一步考察 RBF 网络的泛化能力,采集另一组数据按上述方法进行建模补偿,得到的补偿结果如图 5 所示。由此看出,RBF 神经网络具有较强的泛化能力。



(b) 补偿后

图 5 泛化结果

3 结束语

温度对光纤陀螺仪的零位漂移影响很大,本文提出基于 RBF 神经网络的方法对其进行温度建模并补偿。实验结果表明,该方法能有效地将光纤陀螺仪输出信号内的温漂误差减小 1 个数量级以上,具有很强的非线性曲线拟合能力与模式辨别能力。与传统的基于数值分析的补偿方法相比,该方法具有良好的自学习和泛化能力,鲁棒性好,有较高的实用价值。

参考文献:

- [1] 陈永奇,张春熹,朱奎宝.神经网络在光纤陀螺标度因素温补中的应用[J].压电与声光,2007,29(5):516-518.
CHEN Yongqi, ZHANG Chunxi, ZHU Kuibao. The application of neural network in temperature compensation of FOG scale factor[J]. Piezoelectrics & Acousto-optics, 2007, 29(5): 516-518.
- [2] 魏海坤.神经网络结构设计的理论和方法[M].北京:国防工业出版社,2005.
- [3] 徐丽娜.神经网络控制[M].北京:电子工业出版社,2003.
- [4] 朱荣,张炎华,鲍其莲. RBF 神经网络用于辨识光纤陀螺温度漂移[J].上海交通大学学报,2000,34(2):222-225.
ZHU Rong, ZHANG Yanhua, BAO Qilian. Identification of temperature drift for FOG using RBF neural networks[J]. Journal of Shanghai Jiaotong University, 2000, 34(2): 222-225.